步骤如下：

1. **准备工作：**
   - **注册账号**：访问腾讯云官网注册，国内用户需完成实名认证；也可通过**腾讯云国际站**（[(http://www.tencentcloud.com)]），使用邮箱注册并用护照完成认证。

   - **开通服务**：登录后，进入混元大模型控制台，阅读并同意条款，点击“立即开通”即可。
2. **获取并配置密钥：**
   - 前往客户支持搜索API密钥页面，点击“点击调试”，点击创建api密钥 ，填写参数和昵称即可创建密钥，生成并**妥善保存** `SecretId` 和 `SecretKey` 。

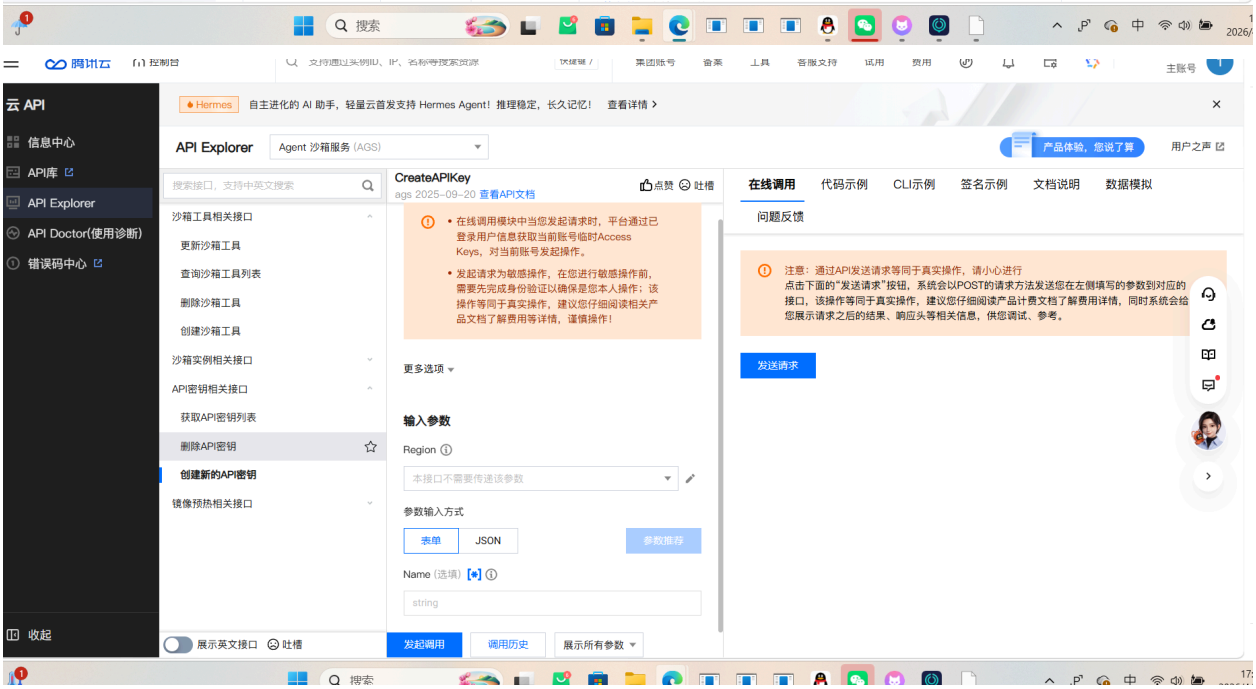

- 在代码的运行环境中设置环境变量，以便安全地配置密钥： bash export TENCENT_SECRET_ID="your_secret_id_here"
  export TENCENT_SECRET_KEY="your_secret_key_here"

3. **编写与运行 Python 代码：**
   混元 API 完全兼容 OpenAI 接口，使用标准 OpenAI SDK 即可调用，无需额外安装专有库。
   - **初始化客户端：**只需修改 `base_url` 和 `api_key`，其他代码保持不变。
     import os
     from openai import OpenAI

client = OpenAI(
api_key=os.environ.get("TENCENT_SECRET_ID"),
base_url="https://api.hunyuan.cloud.tencent.com/v1"
)

1.
   - **启用流式输出**（推荐）：将 `stream` 参数设为 `True` 即可开启流式输出，获得更好的交互体验。 python stream = client.chat.completions.create(
     model="hunyuan-turbos-latest",
     messages=[{"role": "user", "content": "写一首关于夏天的短诗"}],
     stream=True,
)
     for chunk in stream:
     if chunk.choices[0].delta.content is not None:
     print(chunk.choices[0].delta.content, end="")

⚙️ 进阶集成：LangChain 与多语言调用

对于复杂项目，你可以将混元集成到 LangChain 框架，或用其他编程语言调用其 API。

- **使用 LangChain 框架进行开发**
  - 混元在 `langchain_community` 库中提供了 `ChatHunyuan` 类。
  - **Python 示例：** python from langchain_community.chat_models import ChatHunyuan
    from langchain_core.messages import HumanMessage
    chat = ChatHunyuan(
    hunyuan_secret_id='YOUR_SECRET_ID',
    hunyuan_secret_key='YOUR_SECRET_KEY',
    model='hunyuan-turbo',
    streaming=True
)
    response = chat([HumanMessage(content="从Python的角度，谈谈什么是列表推导式")])
    for chunk in response:
    print(chunk.content, end="")
- **多语言支持：PHP 与 Java 的接入**
  - 混元 API 支持多种编程语言。
  - **PHP 示例 (使用官方 SDK)：** php // 安装 SDK: composer require tencentcloud/tencentcloud-sdk-php
    use TencentCloud\Hunyuan\V20230901\HunyuanClient;
    use TencentCloud\Common\Credential;
    $ce = newCeential(CCclient = newHunyuanClient($cred, "ap-guangzhou");
  - **Java 示例 (使用官方 SDK)：** java // Maven 引入 tencentcloud-sdk-java
    import com.tencentcloudapi.hunyuan.v20230901.HunyuanClient;
    import com.tencentcloudapi.common.Credential;
    Credential cred = new Credential("YOUR_SECRET_ID", "YOUR_SECRET_KEY");

HunyuanClient client = new HunyuanClient(cred, "ap-guangzhou"); 详细配置和参数可参考官方 API 文档。

💰 计费与免费额度 (2026年4月)

开通混元服务后，你的账号将自动享有以下免费额度：

- **通用模型**：首次开通赠送 **100万 Token** 资源包，适用于 `hunyuan-turbo` 系列模型。
- **轻量模型**：`hunyuan-lite` 系列模型目前**永久免费**调用。
- **每日免费**：另有每日 **10万 Token** 的后付费模式免费额度，可用于抵扣超出赠送资源包后的用量。

⚠️ **重要提醒**：混元 API 默认使用后付费模式，你**无需**预先充值即可使用赠送额度。只有当这些免费额度全部用完后，才开始产生费用。建议在控制台的“费用中心”开启**费用预警**，以便及时掌控预算。

🤖 模型选择指南：找到最适合你的那一款

腾讯混元提供了多种模型以适应不同场景，你可以根据具体需求选择：

模型系列	核心特点与适用场景	结算方式
hunyuan-lite	**轻量级，响应快**，适合对成本极为敏感的场景，如基础对话、文本分类。	**永久免费**
hunyuan-turbos-latest	**主力模型，性能均衡**，适用于绝大多数通用场景，如内容创作、代码生成。	付费
hunyuan-t1-latest	**擅长深度推理**，专为处理复杂的数学/科学推理、逻辑分析、代码调试等任务设计。	付费
hunyuan-vision	**多模态模型**，支持同时输入图文信息，适用于图文识别、视觉问答等任务。	付费
Hunyuan-MT-7B	**专业翻译模型**，在WMT25比赛中获得30个语种第一，可实现38种语言的高质量互译。	付费或本地部署

☁️ 本地化部署：掌控数据与离线运行

对于数据隐私和安全合规要求极高的场景，你也可以选择本地部署。腾讯云和官方模型库提供了开源模型的本地化方案。

- **适用场景与门槛**：此方案适合数据敏感、需离线运行或进行定制化开发的场景。建议配置 **20GB 以上显存**的 GPU 以达到较好的运行效果。
- **操作指引**：
  1. **环境准备**：建议使用 `vLLM` 作为高性能推理框架。

2. **模型获取**：从 腾讯官方 Hugging Face 仓库 或魔搭社区下载所需模型。
3. **模型部署**：使用 `vLLM` 启动推理服务。例如部署 `hunyuan-mt-7b`：

bash

示例命令，具体参数请参考官方文档

python -m vllm.entrypoints.openai.api_server --model Tencent/Hunyuan-MT-7B --api-key your-api-key

🌐 集成到应用框架：让 AI 为你的服务赋能

除了直接调用 API，你还可以将混元大模型集成到各类开发框架和应用中，快速构建自己的 AI 应用。

平台	接入步骤
腾讯高性能应用服务（HAI）	1. 在 HAI 购买一台 GPU 实例并登录。 2. 在实例上安装 Docker Compose。 3. 通过 GitHub 安装开源工作流平台 Dify。 4. 在 Dify 的设置中，选择“模型供应商”里的 Tencent Hunyuan 并配置密钥。
LobeChat	1. 进入 LobeChat 的设置，点击“语言模型”。 2. 选择模型提供商为 **腾讯混元**。 3. 填入从控制台获取的 **API Key**，点击“检查”即可生效。
Dify / 其他开源工作流	操作步骤与 HAI 中配置 Dify 类似。在平台中找到模型供应商设置，选择 `Tencent HunYuan` 并填写你的 `API Key` 即可。
LangChain 生成 Embedding	1. 设置环境变量 `TENCENT_SECRET_ID` 和 `TENCENT_SECRET_KEY`。 2. 安装 LangChain 社区版：`npm install @langchain/community`。 3. 使用 `TencentHunyuanEmbeddings` 类生成向量。

💡 经验建议

- **环境隔离**：强烈建议通义千问 API Key 写入 `.env` 文件，避免硬编码泄露。
- **参数微调**：`temperature` 参数控制输出随机性（0~1，默认 0.8），内容生成推荐 0.8~1.0，代码生成推荐 0~0.2。`top_p` 同样控制多样性，常与 temperature 配合使用。
- **联网搜索**：模型默认不启用联网，需在请求 `extra_body` 中添加 `"enable_search": True` 开启。